

Raport Analizy Przeżycia

Raport 1 Data wygenerowania: 2025-12-15 21:02:05

Michał Frąckowiak 275951

1. Rozkład Weibulla z trzema parametrami $EW(\alpha, \beta, \gamma)$

Rozważmy zmienną losową $X \sim EW(\alpha, \beta, \gamma)$, gdzie:

- $\alpha > 0$ – parametr kształtu,
- $\beta > 0$ – parametr skali,
- $\gamma \in (0, 1)$ – zewnętrzny parametr kształtu

Funkcja gęstości:

$$f(x) = \frac{\alpha\gamma}{\beta} \left(\frac{x}{\beta}\right)^{\alpha-1} \left[1 - \exp\left(-\left(\frac{x}{\beta}\right)^{\alpha}\right)\right]^{\gamma-1} \exp\left(-\left(\frac{x}{\beta}\right)^{\alpha}\right) \mathbf{1}_{(0, \infty)}(x)$$

```
def dEW(x, alpha, beta, gamma):  
    weibull_pdf = (alpha / beta) * (x / beta)**(alpha - 1) * np.exp(-(x / beta)**alpha)  
    return gamma * weibull_pdf * weibull_cdf**(gamma - 1)
```

Dystrybuanta:

$$F(x) = (1 - e^{-\left(\frac{x}{\beta}\right)^{\alpha}})^{\gamma}, \quad x \geq \gamma$$

```
def pEW(x, alpha, beta, gamma):  
    return (1 - np.exp(-(x / beta)**alpha))**gamma
```

Funkcja kwantylowa:

$$Q(p) = \beta(-\ln(1 - p^{\frac{1}{\gamma}}))^{\frac{1}{\alpha}}, \quad 0 \leq p < 1$$

```
def qEW(p, alpha, beta, gamma):  
    return beta * (-np.log(1 - p**(1/gamma)))**(1/alpha)
```


Funkcja hazardu:

$$h(x) = \frac{\alpha \cdot \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-\left(\frac{x}{\lambda}\right)^k} [1 - e^{-\left(\frac{x}{\lambda}\right)^k}]^{\alpha-1}}{1 - [1 - e^{-\left(\frac{x}{\lambda}\right)^k}]^{\alpha}}, \quad x \geq 0$$

```
def hazard_EW(x, alpha, beta, gamma):  
    f = dEW(x, alpha, beta, gamma)  
    F = pEW(x, alpha, beta, gamma)  
  
    # Unikanie dzielenia przez zero  
    survival = 1 - F  
    return np.where(survival > 1e-10, f / survival, np.inf)
```

1.2. Wizualizacja funkcji hazardu

Funkcja hazardu przedstawia chwilową intensywność zajścia zdarzenia (np. awarii, zgonu) w danym momencie czasu, przy założeniu że zdarzenie nie zaszło wcześniej. Na poniższym wykresie możemy zaobserwować, jak różne kombinacje parametrów α , β i γ wpływają na kształt funkcji hazardu. Rosnąca funkcja hazardu sugeruje, że ryzyko zdarzenia wzrasta z czasem (starzenie się), podczas gdy malejąca funkcja wskazuje na zmniejszające się ryzyko (efekt wczesnej selekcji). Funkcja stała odpowiada rozkładowi wykładniczemu, gdzie ryzyko jest niezależne od czasu.



Wykres przedstawia gęstości prawdopodobieństwa rozkładu Exponentiated Weibull dla różnych zestawów parametrów (α, β, γ) . Wszystkie krzywe startują od zera w punkcie $x=0$, następnie rosną, a dla większych wartości x zachowują się odmiennie w zależności od parametrów.

1.3 Generowanie zmiennych losowych

Korzystamy z próbek z rozkładu wykładniczego

Program do generowania zmiennych





```
def qEW(u, alpha, beta, gamma):  
    return beta * (-np.log(1 - u**(1/gamma)))**(1/alpha)  
  
def rEW(size, alpha, beta, gamma):  
    u = np.random.uniform(0, 1, size)  
    return qEW(u, alpha, beta, gamma)
```

1.4 Wizualizacje próby

Wykresy próbkowe

Poniższy wykres przedstawia porównanie empirycznych rozkładów wygenerowanych próbek z teoretycznymi funkcjami gęstości rozkładu Weibulla. Histogramy pokazują częstość występowania wartości w próbie, podczas gdy linie ciągłe reprezentują wartości teoretyczne. Dobra zgodność między histogramami a krzywymi teoretycznymi potwierdza poprawność implementacji generatora liczb pseudolosowych. Zauważmy, że większe próby ($n=100$) wykazują lepsze dopasowanie do rozkładu teoretycznego niż próby mniejsze ($n=50$), co jest zgodne z prawem wielkich liczb.

Porównanie histogramów i teoretycznej gęstości EW



1.5 Wyniki analizy statystycznej

Tabela prezentuje podstawowe statystyki opisowe dla czterech prób oraz odpowiadające im wartości teoretyczne oparte na rozkładach Weibulla (EW) z parametrami α , β i γ .

STATYSTYKA	WARTOŚĆ TEORETYCZNA	Próba 1 (n=50, a=2, b=4, $\gamma=3$)	Próba 2 (n=100, a=2, b=4, $\gamma=3$)	Próba 3 (n=50, a=2, b=2, $\gamma=1$)	Próba 4 (n=100, a=2, b=2, $\gamma=1$)
Średnia	—	4.8874	5.0783	1.8110	1.8090
Mediana	5.0254 / 1.6651	4.7667	4.9563	1.7761	1.8186
Odchylenie standardowe	—	1.5738	1.6533	0.8874	0.9196
Kwartył dolny (Q1)	3.9883 / 1.0727	3.6673	3.9613	1.0525	1.1387
Kwartył górny (Q3)	6.1865 / 2.3548	5.6743	6.3131	2.3669	2.3634
Rozstęp międzykwartyłowy (IQR)	2.1983 / 1.2821	2.0070	2.3518	1.3144	1.2247
Minimum	—	2.2638	1.7641	0.2587	0.1425
Maksimum	—	8.5716	9.3195	4.1202	4.2944
Rozstęp	—	6.3078	7.5555	3.8615	4.1520

2 Uogólniony rozkład wykładniczy $GE(\lambda, \alpha)$

Rozważamy zmienną losową $X \sim GE(\lambda, \alpha)$, gdzie:

- $\lambda > 0$ – parametr intensywności,
- $\alpha > 0$ – parametr kształtu.

Funkcja gęstości:

$$f(x) = \frac{\alpha\gamma}{\beta} \left(\frac{x}{\beta}\right)^{\alpha-1} \left[1 - \exp\left(-\left(\frac{x}{\beta}\right)^{\alpha}\right)\right]^{\gamma-1} \exp\left(-\left(\frac{x}{\beta}\right)^{\alpha}\right) \mathbf{1}_{(0, \infty)}(x)$$

2.1 Generowanie danych cenzurowanych

Cenzurowanie I-go typu

W cenzurowaniu typu I wszystkie obserwacje są monitorowane do z góry ustalonego czasu t_0 . Obserwacje, które nie zakończyły się zdarzeniem przed tym czasem, są cenzurowane


```

def dexp(lambdaa, alpha):
    t = np.random.rand()
    return -(1/lambdaa) * np.log(1 - t**(1/alpha))

def first_type_error(t0, n = 10, lambdaa = 1, alpha = 1):
    ext = [dexp(lambdaa, alpha) for _ in range(n)]
    delta = []
    for i in range(len(ext)):
        if ext[i] > t0:
            ext[i] = t0
            delta.append(0)
        else:
            delta.append(1)

    return ext, delta

```

Cenzurowanie II-go typu

Cenzurowanie typu II kończy badanie po uzyskaniu z góry ustalonej liczby m zdarzeń.

```

def second_type_error(m, n = 10, lambdaa = 1, alpha = 1):
    ext = [dexp(lambdaa, alpha) for _ in range(n)]
    ext.sort()
    delta = [1] * m + [0] * (n - m)
    ext = ext[:m] + [ext[m-1]] * (n - m)
    return ext, delta

```

Cenzurowanie losowe niezależne

W cenzurowaniu losowym każdy pacjent ma własny, losowy czas cenzurowania, który jest niezależny od czasu do zdarzenia.

```
def random_type_error(eta, n = 10, lambdaa = 1, alpha = 1):
    ext = [dexp(lambdaa, alpha) for _ in range(n)]
    ext2 = [np.random.exponential(scale=eta) for _ in range(n)]
    ext3 = []
    delta = []
    for i in range(len(ext)):
        if ext[i] < ext2[i]:
            ext3.append(ext[i])
            delta.append(1)
        else:
            ext3.append(ext2[i])
            delta.append(0)
    return ext3, delta
```

2.2 Statystyki

Parametry

$n = 20$
 $\lambda = 1.5$
 $\alpha = 2.0$

W każdym przypadku część obserwacji została ocenzurowana W tej próbie liczba kompletnych obserwacji była wysoka (16 z 20), co oznacza niski poziom cenzurowania. W przypadku cenzurowania losowego stopień ocenzurowania jest znacznie wyższy (13 z 20 obserwacji W danych dotyczących cenzurowania typu II również widać umiarkowany poziom cenzurowania oraz zbliżoną medianę do pierwszego przypadku

1 Cenzurowanie typu I

PARAMETR	WARTOŚĆ
n	20
Liczba kompletnych obserwacji	16
Pierwsza obserwacja	0.1032
Mediana	0.5259
Q1	0.3617

2 Cenzurowanie typu II

PARAMETR	WARTOŚĆ
n	20
Liczba pełnych obserwacji (m)	12
Wartość cenzurowania	0.8418
Ostatnia obserwacja	0.1032
Mediana	0.7380

3 Cenzurowanie losowe

PARAMETR	WARTOŚĆ
n	20
Liczba pełnych	7
Liczba ocenzurowanych	13
Min czas	0.0055
Max czas	1.6899
Mediana czasu	0.3015

2.3 Porównanie leków

Porównanie leków A i B

STATYSTYKA	LEK A	LEK B
Liczba obserwacji	20	20
Liczba pełnych	10	10
Pierwsza obserwacja	0.0335	0.0379
Mediana	0.3427	0.3236
Q1	0.1270	0.2136
Q3	0.6280	0.4410
IRQ	0.5010	0.2274

Widać że jest spora różnica pomiędzy grupami pod względem Q3 i IQR

3. Estymacja parametrów

3.1A Estymatory dla cenzurowania typu I

Estymator parametru intensywności λ dla danych cenzurowanych typu I uwzględnia zarówno liczbę zaobserwowanych zdarzeń, jak i całkowity czas obserwacji. Wyższe wartości estymatora wskazują na większą intensywność zdarzenia, czyli krótszy oczekiwany czas do remisji.

LEK	ESTYMATOR λ
Lek A	1.4216
Lek B	1.3459

3.1B Przedziały ufności dla typu I ($\alpha = 0.05$)

Przedział ufności na poziomie 95% dla parametru λ informuje nas, w jakim zakresie z prawdopodobieństwem 0.95 znajduje się prawdziwa wartość parametru.

LEK	DOLNA GRANICA	GÓRNA GRANICA
Lek A	0.7680	3.1506
Lek B	0.7680	3.1506

Przedziały ufności dla typu I ($\alpha = 0.01$)

LEK	DOLNA GRANICA	GÓRNA GRANICA
Lek A	0.6560	4.0720
Lek B	0.6560	4.0720

3.2 Estymatory dla cenzurowania typu II

LEK	ESTYMATOR Λ
Lek A	1.3638
Lek B	1.0371

Przedziały ufności dla typu II ($\alpha = 0.05$)

LEK	DOLNA GRANICA	GÓRNA GRANICA
Lek A	2.8440	0.7983
Lek B	2.1626	0.6070

Przedziały ufności dla typu II ($\alpha = 0.01$)

LEK	DOLNA GRANICA	GÓRNA GRANICA
Lek A	3.6692	0.6820
Lek B	2.7901	0.5186

3.3 Porównanie dokładności estymatorów

Bias estymatorów

Obciążenie (bias) estymatora mierzy odchylenie wartości oczekiwanej estymatora od prawdziwej wartości parametru. Wartości bliskie zeru wskazują na nieobciążony estymator. Obserwujemy, że bias maleje wraz ze wzrostem wielkości próby.

SCENARIUSZ	BIAS TYP I	BIAS TYP II
n=10, t ₀ =0.5	0.064793	0.074287
n=30, t ₀ =0.5	0.019986	0.023175
n=10, t ₀ =1	0.070574	0.074113
n=30, t ₀ =1	0.024437	0.032811
n=10, t ₀ =2	0.070574	0.074113
n=30, t ₀ =2	0.024437	0.032811

MSE estymatorów

Niższe wartości MSE oznaczają lepszą jakość estymacji. Zwiększenie rozmiaru próby znacząco redukuje MSE, co pokazuje korzyści płynące z większych badań. Porównanie MSE dla różnych czasów cenzurowania ($t_0=0.5$ vs $t_0=1$ vs $t_0=2$) ilustruje, jak długość okresu obserwacji wpływa na precyzję estymacji - dłuższa obserwacja dostarcza więcej informacji.

SCENARIUSZ	MSE TYP I	MSE TYP II
n=10, t0=0.5	0.307762	0.331840
n=30, t0=0.5	0.090110	0.094200
n=10, t0=1	0.213416	0.231630
n=30, t0=1	0.058333	0.067485
n=10, t0=2	0.179130	0.276767
n=30, t0=2	0.044129	0.080599

4. Test ilorazu wiarygodności

4.1 Funkcja poziomu krytycznego

```
def exp_likelihood_ratio_test(data, theta0):  
    #n = len(data)  
    r = np.sum(data < np.max(data))  
    data = np.sort(data)  
    data_uncensored = data[:r]  
    s = np.sum(data)  
    #t0 = data_uncensored[-1]  
    theta_hat = r / s  
  
    def log_likelihood(theta, r, s):  
        if theta <= 0:  
            return -np.inf  
        return r * np.log(theta) - theta * s  
  
    log_L_mle = log_likelihood(theta_hat, r, s)  
    log_L_h0 = log_likelihood(theta0, r, s)  
  
    statistic = -2 * (log_L_h0 - log_L_mle)  
    p_value = 1 - stats.chi2.cdf(statistic, df=1)  
  
    return p_value
```

Przeprowadzono test ilorazu wiarygodności dla hipotezy $H_0: \theta = \theta_0$ przeciwko różnym hipotezom alternatywnym.

Parametry symulacji:

- $\theta_0 = 2.0$
- Liczba replikacji: $N = 10000$
- Poziom istotności: $\alpha = 0.05$
- Czas cenzurowania: $t_0 = 1.5$

4.2 Moc testu dla $n = 20$

Moc testu to prawdopodobieństwo odrzucenia fałszywej hipotezy zerowej. Wysoka moc oznacza, że test skutecznie wykrywa odstępstwa od H_0 , gdy one rzeczywiście występują.

Test dwustronny

θ	MOC TESTU
0.8	0.9629
1.2	0.5941
1.8	0.0803
2.1	0.0588

Test prawostronny: $H_1: \theta > \theta_0$

θ	MOC TESTU
1.5	0.0035
2.0	0.0615
2.2	0.1184

Test lewostronny: $H_1: \theta < \theta_0$

θ	MOC TESTU
3.0	0.0000
2.2	0.0151
2.1	0.0276

4.2 Moc testu dla $n = 50$

Zwiększenie wielkości próby z 20 do 50 obserwacji znacząco poprawia moc testu dla wszystkich rozważanych scenariuszy.

Test dwustronny

θ	MOC TESTU
0.8	0.9999
1.2	0.9242
1.8	0.1083
2.1	0.0632

Test prawostronny: $H_1: \theta > \theta_0$

θ	MOC TESTU
1.5	0.0001
2.0	0.0578
2.2	0.1642

Test lewostronny: $H_1: \theta < \theta_0$

θ	MOC TESTU
3.0	0.0000
2.2	0.0094
2.1	0.0215

4.3 Test dla leków A i B ($H_0: \theta = 1$)

Zarówno dla Leku A, jak i Leku B, nie ma podstaw do odrzucenia hipotezy zerowej

LEK	P-VALUE	DECYZJA ($\alpha = 0.05$)
Lek A	0.237355	Nie odrzucamy H_0
Lek B	0.323047	Nie odrzucamy H_0