

Raport Analizy Przeżycia

Data wygenerowania: 2025-12-08 23:41:45


Michał Frąckowiak 275951

Lista 5: Estymatory Kaplana-Meiera i Fleminga-Harringtona

Zadanie 1: Estymatory funkcji przeżycia dla leków A i B


1a) Estymator Kaplana-Meiera

Wygląda na to, że różnice między lekiem A a lekiem B są minimalne, co może sugerować podobną skuteczność w badanym okresie.



1b) Estymator Fleminga-Harringtona

Wyniki testu Fleminga-Harringtona potwierdzają, że nie ma wyraźnej różnicy między grupami. To sugeruje, że obserwowane efekty leczenia są zbliżone niezależnie od metody analizy.




Wnioski: krzywe przeżycia dla obu leków są bardzo zbliżone, co sugeruje podobne działanie leków A i B.

Zadanie 2: Estymatory Kaplana-Meiera z ogonem wykładniczym

Metoda Browna, Hollandera i Kowara polega na estymacji "ogona" funkcji przeżycia (tj. wartości poza ostatnią obserwacją) przy założeniu rozkładu wykładniczego. Parametr θ ogona wykładniczego szacujemy na podstawie wartości estymatora w ostatnim zaobserwowanym punkcie.

Wykresy z ogonem wykładniczym



Przerywane linie przedstawiają ekstrapolację funkcji przeżycia poza zakres obserwacji ($t > 1.0$), zgodnie z propozycją Browna, Hollandera i Kowara.


LEK	S(T_MAX)	Θ (PARAMETR OGONA)
Lek A	0.4792	1.3593
Lek B	0.3668	0.9972

Zadanie 3: Normalność asymptotyczna estymatora Kapłana-Meiera


W celu zbadania własności asymptotycznych estymatora Kapłana-Meiera wygenerowano $M = 1000$ zbiorów danych cenzurowanych I-go typu z rozkładu $GE(\lambda=1.5, \alpha=2.0)$ dla $n = 30, 50, 100$, gdzie $t_0 \approx E(X) = 0.723$.

Histogramy oszacowań $S(t_0)$

Histogramy wskazują, że dane są w przybliżeniu zgodne z rozkładem normalnym.



Histogramy oszacowań $S(2t_0)$



Z wykresu widać, że przedstawione histogramy mają kształt zbliżony do rozkładu normalnego szczególnie dla t_0 . Wraz ze wzrostem liczby obserwacji rozkład zmiennej dąży do normalności.

Lista 6: Estymacja średniego czasu życia

Zadanie 1: Program do estymacji średniego czasu życia

Średni czas życia estymujemy jako pole pod krzywą funkcji przeżycia. Dla danych cenzurowanych stosujemy metodę z ogonem wykładniczym.

1a) Estymator oparty na Kaplanie-Meierze

```
def mean_survival_KM(dane):  
    m = np.sum(dane < np.max(dane))  
    t_max = np.max(dane)  
  
    area, _ = quad(lambda t: Kaplan_Meier(dane, t), 0, t_max, limit=100)  
  
    s_max = Kaplan_Meier(dane, t_max)  
    theta = -t_max / np.log(s_max) if s_max > 0 else 1  
    tail = s_max * theta  
  
    return area + tail
```

1b) Estymator oparty na Flemingu-Harringtonie

```
def mean_survival_FH(dane):  
    m = np.sum(dane < np.max(dane))  
    t_max = np.max(dane)  
  
    area, _ = quad(lambda t: Fleming_Harrington(dane, t), 0, t_max, limit=100)  
  
    s_max = Fleming_Harrington(dane, t_max)  
    theta = -t_max / np.log(s_max) if s_max > 0 else 1  
    tail = s_max * theta  
  
    return area + tail
```

Zadanie 2: Oszacowania średnich czasów do remisji

Na podstawie danych dla leków A i B oszacowano średnie czasy do remisji choroby przy użyciu obu metod.

LEK	KAPLAN-MEIER Z OGONEM	FLEMING-HARRINGTON Z OGONEM	RÓŻNICA
Lek A	1.4321	1.4840	0.0519
Lek B	1.3943	1.4471	0.0528

Porównanie: Wartości oszacowań uzyskane obiema metodami są bardzo zbliżone (różnica < 0.1), co potwierdza stabilność wyników. Oba estymatory dobrze aproksymują średni czas do remisji.

Lista 7: Przedziały ufności dla średniego czasu życia

Zadanie 1: Funkcja do konstrukcji przedziałów ufności

```
def ri(dane, si):
    t = dane[0]
    return np.sum(t >= si)

def di(dane, si):
    t = dane[0]
    delta = dane[1]
    return np.sum((t == si) & (delta == 1))

def Kaplan_Meier(dane, t=0):
    wynik = 1
    m = np.unique(dane[0][(dane[1] == 1) & (dane[0] <= t)])
    for i in m:
        n = ri(dane, i)
        d = di(dane, i)
        wynik *= (1 - d / n)
    return wynik

def mean_survival_KM(si, dane, tau):
    area, _ = quad(lambda k: Kaplan_Meier(dane,k), si, tau, limit=100)
    s_max = Kaplan_Meier(dane, tau)
    tail = - s_max * tau / np.log(s_max)

    return area + tail
```

```

def przedzial_ufnosci_KM(dane, alpha=0.05, tau=0.5):
    t = dane[0]
    delta = dane[1]
    czasy = np.argsort(t)
    t = t[czasy]
    delta = delta[czasy]
    dane = np.array([t, delta])

    zdarzenia = t[delta == 1]
    zdarzenia = zdarzenia[zdarzenia <= tau]
    s_max = Kaplan_Meier(dane, tau)
    suma = 0.0

    for si in zdarzenia:
        if ri(dane, si) - di(dane, si) == 0:
            continue

        integral = mean_survival_KM(si, dane, tau)
        tail = - s_max * tau / np.log(s_max)
        suma += (integral + tail)**2 * di(dane, si) / (ri(dane, si) * (ri(dane, si) - di(dane, si)))

    se = np.sqrt(suma)
    z = stats.norm.ppf(1 - alpha / 2)
    mu_hat = mean_survival_KM(0, dane, tau)

    lower = mu_hat - z * se
    upper = mu_hat + z * se

    return lower, upper

```

gdzie ri to liczba osób w grupie ryzyka w czasie si , a di to liczba zdarzeń w czasie si .

Zadanie 2: Przedziały ufności dla czasu do progresji raka jajnika

Przedziały ufności na poziomie 0.95

Dla $\tau = 500$ dni

GRUPA	DOLNA GRANICA	GÓRNA GRANICA	SZEROKOŚĆ
Niski stopień	311.55	1397.97	1086.42
Wysoki stopień	243.63	443.70	200.07

Dla $\tau = 800$ dni

GRUPA	DOLNA GRANICA	GÓRNA GRANICA	SZEROKOŚĆ
Niski stopień	391.71	2218.25	1826.54
Wysoki stopień	202.67	558.71	356.05

Porównanie przedziałów: Przedziały ufności częściowo się nakładają, jednak grupa z niskim stopniem zaawansowania wykazuje lepsze rokowania. Dla $\tau=800$ przedziały są szersze

Lista 8: Testy porównawcze krzywych przeżycia

Zadanie 1: Testy hipotezy o jednakowych rozkładach


Na poziomie istotności $\alpha = 0.05$ weryfikujemy hipotezę H_0 : funkcje przeżycia w obu grupach pacjentek (niski vs wysoki stopień zaawansowania) są identyczne.

Wyniki testów statystycznych

TEST	STATYSTYKA	P-VALUE	DECYZJA ($\alpha=0.05$)
Log-rank (Mantel-Cox)	5.5664	0.018308	Odrzucamy H_0
Gehan-Breslow (Wilcoxon)	2.2428	0.134234	Nie odrzucamy H_0
Tarone-Ware	3.6819	0.055005	Nie odrzucamy H_0
Peto-Peto	2.6823	0.101468	Nie odrzucamy H_0

Zadanie 2: Wykresy estymatorów i funkcji wagowych


Krzywe Kaplan-Meiera dla obu grup




Analiza Kaplan-Meiera pokazuje wyraźną, istotną różnicę między grupami.

Funkcje wagowe w statystykach testowych

Funkcje wagowe testów porównawczych



Funkcje wagowe testów porównawczych



Interpretacja różnic w wartościach p

Test Log-rank (Mantel-Cox), który równomiernie waży różnice w całym okresie obserwacji, wykazał statystycznie istotną różnicę w funkcjach przeżycia między grupami ($p=0.018308 < 0.05$) co prowadzi do odrzucenia hipotezy zerowej (H_0). Natomiast pozostałe testy (Gehan-Breslow, Tarone-Ware, Peto-Peto), które nadają większą wagę różnicom we wczesnym etapie obserwacji, nie pozwoliły na odrzucenie H_0 . Wniosek jest taki, że istnieją istotne dowody na to, że stopień zaawansowania choroby wpływa na przeżycie pacjentek, szczególnie w późniejszych etapach, a standardowy test Log-rank potwierdza tę różnicę.