

Raport Analizy Przeżycia

Data wygenerowania: 2026-02-13 02:04:49

Michał Frąckowiak 275951

Lista 9: Model Przyspieszonego Czasu Awarii (Weibull AFT) + PH

Zbiór danych: pbc (survival package)

Zmienna zależna: status

Czas przeżycia time

Charakterystyki: age, trt, bili, albumin, edema, stage

```
aft = WeibullAFTFitter()
fit_aft = aft.fit(df, duration_col='time', event_col='status',
formula='trt + age + bili + albumin + edema + stage')

# Rysowanie
times = np.linspace(0, 4000, 400)
survival_function = fit_aft.predict_survival_function(patient_data, times=times)
def survival_at_time_interp(survival_series, t_star):
    times = survival_series.index.values
    values = survival_series.values.flatten()
    return np.interp(t_star, times, values)
prob_survival = survival_at_time_interp(survival_function.iloc[:, 0], 2000)
```

Zadanie 1-2: Oszacowanie parametrów modelu AFT i ich interpretacja


Podsumowanie modelu Weibull AFT

ZMIENNA	COEF	EXP(COEF)	SE(COEF)
Intercept	9.344581	11436.678276	0.641245
trt[T.2.0]	0.053828	1.055303	0.119372
age	-0.017784	0.982373	0.005911
bili	-0.077133	0.925767	0.009403
albumin	0.548100	1.729964	0.153979
edema[T.0.5]	-0.018050	0.982112	0.183171
edema[T.1.0]	-0.777476	0.459564	0.190882
stage[T.2.0]	-0.813191	0.443441	0.652762
stage[T.3.0]	-1.057239	0.347414	0.643547
stage[T.4.0]	-1.375645	0.252677	0.647719
Intercept	0.464411	1.591076	0.073158

Zmienne *age* (wiek) oraz *trt* (leczenie) mają współczynniki $\exp(\text{COEF})$ bardzo bliskie jedności (odpowiednio 0.98 i 1.05), co oznacza, że ich realny wpływ na czas przeżycia w tym modelu jest znikomy. Wyraźny wpływ widać przy *albuminie* ($\exp(\text{COEF}) \approx 1.73$), gdzie każda jednostka wzrostu wydłuża oczekiwany czas do zdarzenia o 73%. Z kolei dla najbardziej zaawansowanego stadium choroby *stage 4* współczynnik wynosi ok. 0.25, co sugeruje, że ta grupa ma czas przeżycia o 75% krótszy w porównaniu do grupy *stage 1*.

Zadanie 3-4: Funkcja przeżycia dla profilu pacjenta

Profil pacjenta: bili=3, albumin=4, edema=0.5



Wykres 1: Szacowana funkcja przeżycia $S(t)$ dla modelu Weibull AFT

Prawdopodobieństwo przeżycia > 2000 dni:

$P(T > 2000)$: = 0.8614 (86.14%)

Zadanie 5-6: Interpretacja współczynników

Współczynniki modelu proporcjonalnych hazardów:

- **Dodatni współczynnik** → wydłużenie czasu przeżycia
- **Ujemny współczynnik** → skrócenie czasu przeżycia


ZMIENNA	OSZACOWANIE (ESTIMATE)
trt2	0.05383
age	-0.01778
bili	-0.07713
albumin	0.54811
edema0.5	-0.01805
edema1	-0.77747
stage2	-0.81320
stage3	-1.05725
stage4	-1.37566
Log(scale)	-0.46441

Interpretacja kluczowych wyników (Model PO):

- **edema1:** Zmienna ta drastycznie zwiększa hazard (ryzyko zgonu). Choć w modelu AFT widzimy wartość **-0.777**, w interpretacji PH odpowiada to silnie dodatniemu wpływowi na ryzyko. Pacjenci z silnym obrzękiem są obciążeni znacznie wyższym prawdopodobieństwem wystąpienia zdarzenia w każdej jednostce czasu.
- **bili:** Każdy wzrost stężenia bilirubiny wiąże się ze zwiększeniem hazardu zgonu. Ujemny współczynnik **-0.077** w modelu czasowym przekłada się na stały, istotny statystycznie ($p < 2 \cdot 10^{-16}$) wzrost ryzyka w modelu PH, co czyni bilirubinę jednym z najsilniejszych markerów postępu choroby.
- **Log(scale):** Parametr **-0.464** (Scale = 0.629) pozwala powiązać model Weibulla z modelem proporcjonalnych hazardów. Ponieważ Scale jest mniejszy od 1, hazard bazowy rośnie wraz z czasem, co oznacza, że pacjenci z czasem stają się coraz bardziej narażeni na wystąpienie zdarzenia.
- **albumin:** Wyższy poziom albuminy wykazuje silne działanie ochronne. Dodatnia wartość **0.548** w modelu AFT odpowiada ujemnemu współczynnikowi w modelu PH, co oznacza istotne statystycznie zmniejszenie hazardu (ryzyka) i tym samym znaczną poprawę rokowań pacjenta.
- **stage4:** Najbardziej zaawansowane stadium choroby (współczynnik **-1.375** w modelu czasowym) generuje najwyższy hazard zgonu spośród wszystkich analizowanych stadiów. Ryzyko rośnie progresywnie wraz ze stopniem zaawansowania ($\text{stage2} < \text{stage3} < \text{stage4}$), co jest spójne z klinicznym obrazem degradacji stanu zdrowia.

Zadanie 7: Funkcje hazardu dla różnych profili


7a-b) Wykresy funkcji hazardu $h(t)$



Wykres 2: Funkcje hazardu dla edema=0.5 i edema=1

Wykres przedstawia funkcję hazardu $h(t)$, gdzie wyższa wartość oznacza większe ryzyko wystąpienia zdarzenia w danym czasie. Grupa edema=1 (linia czerwona) wykazuje znacznie wyższy poziom hazardu niż grupa edema=0.5, co sugeruje ponad dwukrotnie większe ryzyko dla tych pacjentów w szczytowym momencie (ok. 2000 dnia). Podczas gdy ryzyko w grupie niebieskiej rośnie niemal liniowo i stabilizuje się na niskim poziomie, grupa czerwona osiąga wyraźne maksimum, po czym tempo przyrostu ryzyka zaczyna powoli spadać.

Wykresy logarytmów funkcji hazardu $\ln(h(t))$




Wykres 3: Logarytmy funkcji hazardu

Wątpliwości co do modelu proporcjonalnych hazardów?

W modelu PH linie $\ln(h(t))$ powinny być równoległe (stała różnica). Linie nie zbiegają do siebie zatem nie ma podstaw by stwierdzić naruszenie założenia PH.

Zadanie 8-9: Porównanie funkcji przeżycia

Funkcje przeżycia dla obu profili




Wykres 4: Porównanie funkcji przeżycia dla $edema=0.5$ i $edema=1$

PH Prawdopodobieństwa przeżycia > 2000 dni:

edema=0.5 0.8702 (87.02%)

edema=1 0.6669 (66.69%)

Duża rozpiętość krzywych potwierdza, że stopień obrzęku (edema) jest kluczowym czynnikiem drastycznie skracającym przewidywany czas przeżycia



Wykres 5: Porównanie funkcji przeżycia dla różnych modeli

Porównanie z zadaniem 3: Wartości są porównywalne.

Lista 10: Model Proporcjonalnych Hazardów Coxa

Zbiór danych: pbc (survival package)
Zmienna zależna: status
Czas przeżycia time
Charakterystyki: age, trt, bili, albumin, edema, stage

Zadanie 1-2: Oszacowanie parametrów modelu Coxa i ich interpretacja

Podsumowanie modelu Cox PH

ZMIENNA	COEF	EXP(COEF)	SE(COEF)
C(trt)[T.2.0]	-0.076042	0.926777	0.190286
age	0.028356	1.028761	0.009469
bili	0.125099	1.133260	0.015761
albumin	-0.897688	0.407511	0.255766
C(edema)[T.0.5]	0.015449	1.015569	0.292975
C(edema)[T.1.0]	1.112955	3.043337	0.315145
C(stage)[T.2.0]	1.315622	3.727067	1.034535
C(stage)[T.3.0]	1.724696	5.610815	1.016921
C(stage)[T.4.0]	2.212182	9.135628	1.020174


Interpretacja współczynników Coxa: (coef)

$\exp(\beta)$ = Hazard Ratio (HR) - stosunek ryzyka


- $HR > 1 \rightarrow$ zwiększone ryzyko zgonu
- $HR < 1 \rightarrow$ zmniejszone ryzyko zgonu

Zadanie 3: Bazowe funkcje modelu Coxa

Bazowa skumulowana funkcja hazardu



Bazowa funkcja przeżycia




```
cph = CoxPHFitter()
cph.fit(dane, duration_col='time', event_col='status')

bh = cph.baseline_cumulative_hazard_ # Bazowa skumulowana funkcja hazardu
bs = cph.baseline_survival_ # Bazowa funkcja przeżycia

_, patient_profile1 = wczytaj_i_przygotuj_dane(0.5)
_, patient_profile2 = wczytaj_i_przygotuj_dane(1)
hazard_function1 = cph.predict_cumulative_hazard(patient_profile1)
hazard_function2 = cph.predict_cumulative_hazard(patient_profile2)
```


Zadanie 4: Skumulowane funkcje hazardu dla profili pacjentów

Wykresy skumulowanego hazardu



Wykres 5: Skumulowany hazard dla ph.ecog=1 i ph.ecog=2


Logarytmy skumulowanego hazardu



Wykres 6: Logarytmy skumulowanego hazardu

Linie $\ln(H(t))$ powinny być równoległe w modelu PH i faktycznie są, więc nie ma naruszenia założenia proporcjonalnych hazardów.

Zadanie 5-6: Funkcje przeżycia



Wykres 7: Funkcje przeżycia z modelu Coxa

Cox Prawdopodobieństwa przeżycia > 2000 dni:

edema=0.5: 0.8782 (87.82%)


edema=1: 0.6775 (67.75%)

PH Prawdopodobieństwa przeżycia > 2000 dni:

edema=0.5 0.8702 (87.02%)

edema=1 0.6669 (66.69%)

Wykres hazardu pokazuje, że grupa $ph.edema=1$ jest obarczona ponad dwukrotnie wyższym ryzykiem niż grupa 0.5, co drastycznie obniża krzywe przeżycia. Przy tych samych parametrach, pacjent z $edema=1$ ma tylko 67% szans na przeżycie 2000 dni, podczas gdy przy $edema=0.5$ szanse te rosną do 87%.



Porównanie z Listą 9:

Model Coxa daje prawie identyczne oszacowania jak model Weibull AFT.

Lista 11: Model proporcjonalnych szans

Zbiór danych: pbc (survival package)
Zmienna zależna: status
Czas przeżycia time
Charakterystyki: age, trt, bili, albumin, edema, stage

Zadanie 1-2: Oszacowanie parametrów modelu OrderedModel i ich interpretacja


Parametry modelu

ZMIENNA	WARTOŚĆ
('alpha_', 'Intercept')	9.002411
('alpha_', 'trt[T.2.0]')	-0.011572
('alpha_', 'age')	-0.020721
('alpha_', 'bili')	-0.091286
('alpha_', 'albumin')	0.490654
('alpha_', 'edema[T.0.5]')	-0.219720
('alpha_', 'edema[T.1.0]')	-0.986320
('alpha_', 'stage[T.2.0]')	-0.642797
('alpha_', 'stage[T.3.0]')	-0.893883
('alpha_', 'stage[T.4.0]')	-1.276909
('beta_', 'Intercept')	0.705642

Wartości są abliżone do tych z Weibull AFT, PH i CoxPH, co jest zgodne z oczekiwaniami. Interpretujemy je tak samo jak w modelu Weibul IAF.


Zadanie 3: Bazowe funkcje modelu

Bazowa skumulowana funkcja hazardu



Oszacowanie bazowego hazardu


Bazowa funkcja przeżycia



Oszacowanie bazowej funkcji przeżycia


Zadanie 4: Porównanie z modelem Coxa

Skumulowane funkcje hazardu



Wykres 8: Skumulowany hazard

Logarytmy skumulowanego hazardu




Wykres 9: Logarytmy skumulowanego hazardu


Porównanie z Listą 10:

Otrzymane wykresy funkcji hazardu oraz logarytmu skumulowanego hazardu są wyraźnie podobne do tych uzyskiwanych w modelu Coxa

Zadanie 5-6: Funkcje przeżycia i porównanie



Wykres 10: Funkcje przeżycia dla kategorii czasu



Wykres 10: Funkcje przeżycia dla kategorii czasu

Prawdopodobieństwa przeżycia dla 2000 dni:

edema=0.5: 0.8224 (82.24%)

Cox Prawdopodobieństwa przeżycia > 2000 dni:

edema=0.5: 0.8782 (87.82%)

Porównanie z Listą 10:

Wzualiacja pokazuje umiarkowaną zgodność pomiędzy modelem proporcjonalnych szans a modelem Coxa. Widać wyraźne rozdzielenie krzywych dla edema=0.5: oraz edema=1. Dla edema=0.5 oszacowanie różni się o około 5%.

Lista 12: Testy Istotności Zmiennych

Zadanie 1: Model przyspieszeniowego czasu awarii (AFT Weibull)

Poziom istotności: $\alpha = 0.05$

Model pełny: $\text{time} \sim \text{age} + \text{bili} + \text{albumin} + \text{edema} + \text{stage} + \text{trt}$

1a) Test istotności zmiennej age

Hipoteza zerowa H_0 : Zmienna age nie jest istotna w modelu (współczynnik = 0)

```
aft_full = WeibullAFTFitter()
aft_full.fit(df, duration_col='time', event_col='event')

# Test Walda
age_summary = aft_full.summary[aft_full.summary['covariate'] == 'age']
wald_stat = (age_summary['coef'] / age_summary['se(coef)'])**2
wald_pvalue = 1 - chi2.cdf(wald_stat, df=1)

# Test ilorazu wiarygodności (LRT)
aft_no_age = WeibullAFTFitter()
aft_no_age.fit(df[['time', 'event', 'bili', 'albumin', 'edema', 'stage', 'trt']],
               duration_col='time', event_col='event')
lrt_stat = 2 * (aft_full.log_likelihood_ - aft_no_age.log_likelihood_)
lrt_pvalue = 1 - chi2.cdf(lrt_stat, df=1)
```

TEST	P-VALUE	DECYZJA
Test Walda	0.002608	Zmienna age JEST istotna ($p < 0.05$)
Test ilorazu wiarygodności (LRT)	0.002530	

Wniosek: Zmienna age JEST istotna ($p < 0.05$)

1b) Test istotności zmiennej trt

Hipoteza zerowa H_0 : Zmienna trt nie jest istotna w modelu (współczynnik = 0)

TEST	P-VALUE	DECYZJA
Test Walda	0.890130	Zmienna trt NIE jest istotna ($p \geq 0.05$)
Test ilorazu wiarygodności (LRT)	0.890083	

Wniosek: Zmienna trt NIE jest istotna ($p \geq 0.05$)

1c) Test istotności zmiennej stage

Hipoteza zerowa H_0 : Rozkład czasu życia jest taki sam dla pacjentów w różnych stadiach choroby (stage 1, 2, 3, 4)

TEST	P-VALUE	DECYZJA
Test ilorazu wiarygodności (LRT)	0.000827	Zmienna stage JEST istotna ($p < 0.05$)

Wniosek: Zmienna stage JEST istotna ($p < 0.05$)

Zadanie 2: Model proporcjonalnych hazardow Coxa

Poziom istotnosci: alpha = 0.05

Model pelny: time ~ age + bili + albumin + edema + stage + trt

2a) Test istotnosci zmiennej age

Hipoteza zerowa H0: Zmienna age nie jest istotna w modelu (wspolczynnik = 0)

```
cox_full = CoxPHFitter()
    cox_full.fit(df, duration_col='time', event_col='event')

    # Test Walda
    age_summary = cox_full.summary[cox_full.summary['covariate'] == 'age']
    wald_stat = (age_summary['coef'] / age_summary['se(coef)'])**2
    wald_pvalue = 1 - chi2.cdf(wald_stat, df=1)

    # Test ilorazu wiarygodnosci (LRT)
    cox_no_age = CoxPHFitter()
    cox_no_age.fit(df[['time', 'event', 'bili', 'albumin', 'edema', 'stage', 'trt']],
        duration_col='time', event_col='event')
    lrt_stat = 2 * (cox_full.log_likelihood_ - cox_no_age.log_likelihood_)
    lrt_pvalue = 1 - chi2.cdf(lrt_stat, df=1)
```

TEST	P-VALUE	DECYZJA
Test Walda	0.002455	Zmienna age JEST istotna (p < 0.05)
Test ilorazu wiarygodnosci (LRT)	0.002521	

Wniosek: Zmienna age JEST istotna (p < 0.05)

2b) Test istotności zmiennej trt

Hipoteza zerowa H_0 : Zmienna trt nie jest istotna w modelu (współczynnik = 0)

TEST	P-VALUE	DECYZJA
Test Walda	0.896769	Zmienna trt NIE jest istotna ($p \geq 0.05$)
Test ilorazu wiarygodności (LRT)	0.896785	

Wniosek: Zmienna trt NIE jest istotna ($p \geq 0.05$)

2c) Test istotności zmiennej stage

Hipoteza zerowa H_0 : Rozkład czasu życia jest taki sam dla pacjentów w różnych stadiach choroby (stage 1, 2, 3, 4)

TEST	P-VALUE	DECYZJA
Test ilorazu wiarygodności (LRT)	0.000982	Zmienna stage JEST istotna ($p < 0.05$)

Wniosek: Zmienna stage JEST istotna ($p < 0.05$)

Zadanie 3: Selekcja zmiennych dla modelu AFT

3a) Metoda eliminacji wstecznej (backward elimination)

Rozpoczynamy od pełnego modelu i iteracyjnie usuwamy najmniej istotną zmienną (najwyższe p-value z testu LRT), dopóki wszystkie zmienne nie będą istotne ($p < 0.05$).

```
current_vars = ['age', 'bili', 'albumin', 'edema', 'stage', 'trt']

while True:

    # Dopasuj model z aktualnymi zmiennymi
    current_model = WeibullAFTFitter()
    current_model.fit(df[['time', 'event']] + current_vars,
                      duration_col='time', event_col='event')

    max_pvalue = 0
    var_to_remove = None
    for var in current_vars:
        reduced_vars = [v for v in current_vars if v != var]
        reduced_model = WeibullAFTFitter()
        reduced_model.fit(df[['time', 'event']] + reduced_vars,
                          duration_col='time', event_col='event')

        lrt_stat = 2 * (current_model.log_likelihood_ - reduced_model.log_likelihood_)
        pvalue = 1 - chi2.cdf(lrt_stat, df=1)

        if pvalue > max_pvalue:
            max_pvalue = pvalue
            var_to_remove = var

    # Jeśli wszystkie zmienne istotne (p < 0.05), zakończ
    if max_pvalue < 0.05:
        break

    current_vars.remove(var_to_remove)
```

Zmienne końcowe: age, bili, albumin, edema, stage

3b) Kryterium AIC

Wybieramy model o najniższej wartości $AIC = -2 \cdot \log\text{-likelihood} + 2 \cdot k$, gdzie k to liczba parametrów.

```
from itertools import combinations

best_aic = inf
best_vars = []

# Przeszukaj wszystkie możliwe kombinacje zmiennych
for r in range(1, 7):
    for var_combo in combinations(['age', 'bili', 'albumin', 'edema', 'stage', 'trt'], r):
        model = WeibullAFTFitter()
        model.fit(df[['time', 'event'] + list(var_combo)],
                  duration_col='time', event_col='event')

        aic = -2 * model.log_likelihood_ + 2 * len(model.params_)

        if aic < best_aic:
            best_aic = aic
            best_vars = list(var_combo)
```

Najlepsze zmienne: age, bili, albumin, edema, stage, trt

3c) Kryterium BIC

Wybieramy model o najniższej wartości $BIC = -2 \cdot \log\text{-likelihood} + \log(n) \cdot k$, gdzie n to liczba obserwacji, k to liczba parametrów.

```
best_bic = inf
best_vars = []
n = len(df)

# Przeszukaj wszystkie możliwe kombinacje zmiennych
for r in range(1, 7):
    for var_combo in combinations(['age', 'bili', 'albumin', 'edema', 'stage', 'trt'], r):
        model = WeibullAFTFitter()
        model.fit(df[['time', 'event'] + list(var_combo)],
                  duration_col='time', event_col='event')

        bic = -2 * model.log_likelihood_ + log(n) * len(model.params_)

        if bic < best_bic:
            best_bic = bic
            best_vars = list(var_combo)
```

Najlepsze zmienne: age, bili, albumin, edema, stage, trt

Zadanie 4: Selekcja zmiennych dla modelu Coxa

4a) Metoda eliminacji wstecznej (backward elimination)

Analogicznie jak w zadaniu 3a, ale dla modelu Coxa.

```
current_vars = ['age', 'bili', 'albumin', 'edema', 'stage', 'trt']
while True:
    current_model = CoxPHFitter()
    current_model.fit(df[['time', 'event'] + current_vars],
                     duration_col='time', event_col='event')

    max_pvalue = 0
    var_to_remove = None
    for var in current_vars:
        reduced_vars = [v for v in current_vars if v != var]
        reduced_model = CoxPHFitter()
        reduced_model.fit(df[['time', 'event'] + reduced_vars],
                         duration_col='time', event_col='event')

        lrt_stat = 2 * (current_model.log_likelihood_ - reduced_model.log_likelihood_)
        pvalue = 1 - chi2.cdf(lrt_stat, df=1)
        if pvalue > max_pvalue:
            max_pvalue = pvalue
            var_to_remove = var
    if max_pvalue < 0.05:
        break
    current_vars.remove(var_to_remove)
```

Zmienne końcowe: age, bili, albumin, edema, stage

4b) Kryterium AIC

Wybieramy model o najniższej wartości AIC.

```
best_aic = inf
best_vars = []

for r in range(1, 7):
    for var_combo in combinations(['age', 'bili', 'albumin', 'edema', 'stage', 'trt'], r):
        model = CoxPHFitter()
        model.fit(df[['time', 'event'] + list(var_combo)],
                  duration_col='time', event_col='event')

        aic = -2 * model.log_likelihood_ + 2 * len(model.params_)

        if aic < best_aic:
            best_aic = aic
            best_vars = list(var_combo)
```

Najlepsze zmienne: age, bili, albumin, edema, stage, trt

4c) Kryterium BIC

Wybieramy model o najniższej wartości BIC.

Najlepsze zmienne: age, bili, albumin, edema, stage, trt